

Bayesovská regrese

Karel Bílek

2013

1 Regrese se známou σ^2

1.1 Definice problému

Definice 1 (Model regrese se známou σ^2).

- Trénovací data jsou vstupy $x_{old} = (x_1, x_2 \dots x_n)^T$, výstupy $y_{old} = (y_1, y_2 \dots y_n)^T$, můžou být diskrétní i spojité.
- Ted' chci novému vstupu x_{new} chci přiřadit výstup y_{new} . Předpokládám model dat R , popsany níže.
- Model dat R vypadá následovně:
 - známe σ^2
 - známe nějakou konečnou množinu bázových funkcí $\phi_i(x)$, $i = 1 \dots M$.
 - $y_i = f(x_i) + \varepsilon_i$, kde
 - $\varepsilon_i \sim^{iid} \mathcal{N}(0, \sigma^2)$ a
 - $f(x) = \sum_{m=1}^M w_m \phi_m(x)$.
- Tj. model je lineární kombinace funkcí, zašuměná o nějaké ε .
- Parametry modelu jsou tedy váhy $w = (w_1, w_2 \dots w_M)^T$, struktura modelu je definována množinou funkcí.
- Dále si v rámci modelu zadefinujeme priorní pravděpodobnost $w \sim \mathcal{N}(\mu_0, \Sigma_0)$
 - Tj. konstanty jsou $\mu_0, \Sigma_0, \sigma^2, \{\phi_i\}$, chápu to vše jako součást modelu R .

1.2 Pomocná lemmata

Zde si postupně napíšu a dokážu lemmata, co potom využiji ve výpočtech prediktivních funkcí dál.

Pozn. k notaci: Konstantu u výpočtu logaritmu si často budu značit c . Pokud někde napíšu $f(x) = a(x) + c = b(x) + c$, nemusí jít o stejnou konstantu, je tím prostě myšleno „něco, co nezávisí na x “.

Lemma 1. M je symetrická matice, $a^T M b$ je skalár, potom $a^T M b = b^T M a$

Důkaz.

- $a^T M b = (a^T M b)^T$, protože jde o skalár
- $((a^T M) b)^T = b^T (a^T M)^T$, protože $(ab)^T = b^T a^T$
- $b^T (a^T M)^T = b^T M^T a^{TT}$
- $b^T M^T a^{TT} = b^T M a$, protože M je symetrická a $a^{TT} = a$

□

Lemma 2. M je symetrická matice. Potom

$$(a - b)^T M (a - b) = a^T M a - 2a^T M b + b^T M b = a^T M a - 2b^T M a + b^T M b$$

Důkaz.

- $\left((a - b)^T M \right) (a - b) = (a^T M - b^T M) (a - b) = a^T M a - a^T M b - b^T M a + b^T M b$ - „hloupé“ rozepsání
- $a^T M a - a^T M b - b^T M a + b^T M b = a^T M a - 2a^T M b + b^T M b$, protože M je symetrická a Lemma 1. \square

Lemma 3 (Převod na čtverec). Λ je pozitivně definitní matice. Potom

$$-\frac{1}{2}x^T \Lambda x + x^T m = -\frac{1}{2}(x - \Lambda^{-1}m)^T \Lambda (x - \Lambda^{-1}m) + \frac{1}{2}m^T \Lambda^{-1}m$$

Pozn.: tuto „zvláštní“ formu používám proto, že takto se vyskytuje v exponentu \mathcal{N} .

Pozn. 2: Správně bych při použití tohoto lemmatu měl vždy kontrolovat, jestli jde o pozitivně definitní matici. Jelikož tohle já ale neumím, tak to dělat nebudu.

Důkaz.

- Podle Lemma 2 $(x - \Lambda^{-1}m)^T \Lambda (x - \Lambda^{-1}m) = x^T \Lambda x - 2x^T \Lambda (\Lambda^{-1}m) + (\Lambda^{-1}m)^T \Lambda (\Lambda^{-1}m)$
- protože $\Lambda \Lambda^{-1} = 1$, tak $(x - \Lambda^{-1}m)^T \Lambda (x - \Lambda^{-1}m) = x^T \Lambda x - 2x^T m + (\Lambda^{-1}m)^T m$
- Poslední člen lze přepsat jako $m^T \Lambda^{-1}m$, protože Λ^{-1} je symetrická.
- převod doleva: $(x - \Lambda^{-1}m)^T \Lambda (x - \Lambda^{-1}m) - m^T \Lambda^{-1}m = x^T \Lambda x - 2x^T m$
- Vynásobíme $-\frac{1}{2}$: $-\frac{1}{2}(x - \Lambda^{-1}m)^T \Lambda (x - \Lambda^{-1}m) + \frac{1}{2}m^T \Lambda^{-1}m = -\frac{1}{2}x^T \Lambda x + x^T m$ \square

Lemma 4 (Násobení matice ze stran). $\begin{pmatrix} x \\ y \end{pmatrix}^T \begin{pmatrix} A & B \\ C & D \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix} = x^T A u + y^T D v + x^T B v + y^T C u$

Lemma 5. *Mějme*

$$f(y) = \int g(y)p(x, y)dx,$$

kde $g(y)$ je nějaká funkce nezávislá na x , a $p(x, y) \propto \bar{p}(x|y)$,

$$\bar{p}(x|y) \sim \mathcal{N}.$$

Pak $f(y) \propto g(y)$.

(Pozn.: $p(x, y) \propto \bar{p}(x|y)$ znamená, že konstanta c , přes kterou jsou proporcionální, nesmí záviset ani na x ani na y .)

Důkaz.

- $f(y) = \int g(y)p(x, y)dx = g(y) \int p(x, y)dx$ - v rámci integrálu je $g(y)$ konstanta, tak jí můžu vytknout
- $\int \bar{p}(x|y)dx = 1$
- $\int p(x, y)dx = \int c \bar{p}(x|y)dx = c \int \bar{p}(x|y)dx$ protože c nezávisí na x
- $c \int \bar{p}(x|y)dx = c$
- $g(y) \int p(x, y)dx = g(y) c \propto g(y)$ protože c nezávisí na y \square

Definice 2. Necht' $x = \begin{pmatrix} x_a \\ x_b \end{pmatrix}$, $p(x) = \mathcal{N}(x|\mu, \Sigma)$. μ se potom dá napsat jako $\mu = \begin{pmatrix} \mu_a \\ \mu_b \end{pmatrix}$. Podobně matice Σ lze rozepsat jako $\Sigma = \begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}$

Lemma 6.

$$\begin{pmatrix} A & B \\ C & D \end{pmatrix}^{-1} = \begin{pmatrix} M & -MBD^{-1} \\ -D^{-1}CM & D^{-1} + D^{-1}CMBD^{-1} \end{pmatrix},$$

kde

$$M = (A - BD^{-1}C)^{-1}$$

Proof. Asi bych na to šel sporem. Ale udělal bych tam hromadu chyb, tak to nedělám. \square

Definice 3. Inverzi kovarianční matice nazvu Λ^{-1} , $\Lambda = \Sigma^{-1}$.

Definice 4. Λ se dá taky rozepsat jako $\Lambda = \begin{pmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{pmatrix}$

Lemma 7. Platí, že $\Lambda_{ab}^T = \Lambda_{ba}$

Důkaz.

- pozitivně definitní matice je symetrická, Λ je p.d. protože Σ je
- z toho už je to vidět \square

Lemma 8 (Marginál). Definuju $x = \begin{pmatrix} x_a \\ x_b \end{pmatrix}$, $p(x) \sim \mathcal{N}(x|\mu, \Sigma)$. Potom platí, že marginál

$$p(x_a) = \int p(x) dx_b \sim \mathcal{N}(\Sigma_{aa}, \mu_a)$$

Důkaz.

- $\ln p(x) = -\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu) + c$, c nezávisí na x , z definice.
- $-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu) = -\frac{1}{2}(x^T \Sigma^{-1} x) + (x^T \Sigma^{-1} \mu) - [\frac{1}{2} \mu^T \Sigma^{-1} \mu]$
podle Lemma 2, poslední člen můžu brát jako konstantu a tedy dále ignorovat.
- $x^T \Sigma^{-1} x = x_a^T \Lambda_{aa} x_a + 2x_b^T \Lambda_{ba} x_a + x_b^T \Lambda_{bb} x_b$ (kvůli Lemmatům 1, 4, 7)
- $x^T \Sigma^{-1} \mu = x_a^T \Lambda_{aa} \mu_a + x_a^T \Lambda_{ab} \mu_b + x_b^T \Lambda_{ba} \mu_a + x_b^T \Lambda_{bb} \mu_b$
- $\ln p(x) = -\frac{1}{2}(x_a^T \Lambda_{aa} x_a + 2x_b^T \Lambda_{ba} x_a + x_b^T \Lambda_{bb} x_b) +$
 $+ (x_a^T \Lambda_{aa} \mu_a + x_a^T \Lambda_{ab} \mu_b + x_b^T \Lambda_{ba} \mu_a + x_b^T \Lambda_{bb} \mu_b) + c$ (dosazení)
- $\ln p(x) = -\frac{1}{2}x_a^T \Lambda_{aa} x_a - x_b^T \Lambda_{ba} x_a - \frac{1}{2}x_b^T \Lambda_{bb} x_b +$
 $+ x_a^T \Lambda_{aa} \mu_a + x_a^T \Lambda_{ab} \mu_b + x_b^T \Lambda_{ba} \mu_a + x_b^T \Lambda_{bb} \mu_b + c$ (roznásobení)
- $\ln p(x) = -\frac{1}{2}x_b^T \Lambda_{bb} x_b + x_b^T (\Lambda_{ba} (-x_a + \mu_a) + \Lambda_{bb} \mu_b) + [x_a^T \Lambda_{aa} (-\frac{1}{2}x_a + \mu_a) + x_a^T \Lambda_{ab} \mu_b] + c$
(popřehazování)
- označíme si celý termín $(\Lambda_{ba} (-x_a + \mu_a) + \Lambda_{bb} \mu_b)$ jako m
 - Díváme se na část bez závorky vpravo.
 - $-\frac{1}{2}x_b^T \Lambda_{bb} x_b + x_b^T m$
 - Podle Lemmatu 3 můžu přepsat na $-\frac{1}{2}(x_b - \Lambda_{bb}^{-1} m)^T \Lambda_{bb} (x_b - \Lambda_{bb}^{-1} m) + \frac{1}{2} m^T \Lambda_{bb}^{-1} m$
- $\ln p(x_a) = -\frac{1}{2}(x_b - \Lambda_{bb}^{-1} m)^T \Lambda_{bb} (x_b - \Lambda_{bb}^{-1} m) +$
 $+ [\frac{1}{2} m^T \Lambda_{bb}^{-1} m + x_a^T \Lambda_{aa} (-\frac{1}{2}x_a + \mu_a) + x_a^T \Lambda_{ab} \mu_b]$ (viz předchozí body)
- $p(x_a) = \int c_1 \exp\left(-\frac{1}{2}(x_b - \Lambda_{bb}^{-1} m)^T \Lambda_{bb} (x_b - \Lambda_{bb}^{-1} m)\right) \cdot$
 $\exp\left(\frac{1}{2} m^T \Lambda_{bb}^{-1} m + x_a^T \Lambda_{aa} (-\frac{1}{2}x_a + \mu_a) + x_a^T \Lambda_{ab} \mu_b\right) dx_b$

¹velká lambda. Anglicky se nazývá *precision matrix*, česky vůbec nevím

- Toto vyhovuje Lemma 5 - $p(x, y)$ z lemmatu je první a druhý člen, druhý je exponentem mult. gausiánu a liší se od něj tedy pouze normalizační konstantou, závislou na Λ_{bb} ; a $g(y)$ z lemmatu je třetí člen (m nezávisí na x_b)
- tj. $p(x_a) \propto \exp\left(\frac{1}{2}m^T \Lambda_{bb}^{-1}m + x_a^T \Lambda_{aa}\left(-\frac{1}{2}x_a + \mu_a\right) + x_a^T \Lambda_{ab}\mu_b\right)$
- Jdu dělat úpravy $\frac{1}{2}m^T \Lambda_{bb}^{-1}m + x_a^T \Lambda_{aa}\left(-\frac{1}{2}x_a + \mu_a\right) + x_a^T \Lambda_{ab}\mu_b$
 - pozn: $(a - b)^T \Sigma c = c^T \Sigma (a - b) = c^T \Sigma a - c^T \Sigma b = a^T \Sigma c - b^T \Sigma c$, pokud jsou výsledky skaláry a $\Sigma^T = \Sigma$
 - $m^T \Lambda_{bb}^{-1}m = (\Lambda_{ba}(-x_a + \mu_a) + \Lambda_{bb}\mu_b)^T \Lambda_{bb}^{-1}(\Lambda_{ba}(x_a + \mu_a) + \Lambda_{bb}\mu_b) =$
 $= (\Lambda_{ba}(-x_a + \mu_a))^T \Lambda_{bb}^{-1}(\Lambda_{ba}(-x_a + \mu_a)) +$
 $+ 2(\Lambda_{ba}(-x_a + \mu_a))^T \Lambda_{bb}^{-1}\Lambda_{bb}\mu_b + (\Lambda_{bb}\mu_b)^T \Lambda_{bb}^{-1}\Lambda_{bb}\mu_b =$
 $= (\Lambda_{ba}\mu_a - \Lambda_{ba}x_a)^T \Lambda_{bb}^{-1}(\Lambda_{ba}\mu_a - \Lambda_{ba}x_a) +$
 $+ 2(\Lambda_{ba}\mu_a - \Lambda_{ba}x_a)^T \Lambda_{bb}^{-1}\Lambda_{bb}\mu_b + \mu_b^T \Lambda_{bb}^T \Lambda_{bb}^{-1}\Lambda_{bb}\mu_b =$
 $= (\Lambda_{ba}\mu_a)^T \Lambda_{bb}^{-1}\Lambda_{ba}\mu_a - 2(\Lambda_{ba}\mu_a)^T \Lambda_{bb}^{-1}\Lambda_{ba}x_a + (\Lambda_{ba}x_a)^T \Lambda_{bb}^{-1}\Lambda_{ba}x_a +$
 $+ 2(\Lambda_{ba}\mu_a)^T \Lambda_{bb}^{-1}\Lambda_{bb}\mu_b - 2(\Lambda_{ba}x_a)^T \Lambda_{bb}^{-1}\Lambda_{bb}\mu_b + \mu_b^T \Lambda_{bb}^T \Lambda_{bb}^{-1}\Lambda_{bb}\mu_b =$
 $= c_1 - 2x_a^T (\Lambda_{ba}^T \Lambda_{bb}^{-1}\Lambda_{ba}\mu_a) + x_a^T (\Lambda_{ba}^T \Lambda_{bb}^{-1}\Lambda_{ba})x_a + c_2 - 2x_a^T (\Lambda_{ba}^T \Lambda_{bb}^{-1}\Lambda_{bb}\mu_b) + c_3 =$
 $= -2x_a^T (\Lambda_{ba}^T \Lambda_{bb}^{-1}\Lambda_{ba}\mu_a) + x_a^T (\Lambda_{ba}^T \Lambda_{bb}^{-1}\Lambda_{ba})x_a - 2x_a^T (\Lambda_{ba}^T \mu_b) + c_4$
 $= -2x_a^T (\Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba}\mu_a) + x_a^T (\Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba})x_a - 2x_a^T (\Lambda_{ab}\mu_b) + c_4$
 kde c_n jsou konstanty nezávislé na x_a
 - $\frac{1}{2}m^T \Lambda_{bb}^{-1}m + x_a^T \Lambda_{aa}\left(-\frac{1}{2}x_a + \mu_a\right) + x_a^T \Lambda_{ab}\mu_b =$
 $= \frac{1}{2}(-2x_a^T (\Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba}\mu_a) + x_a^T (\Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba})x_a - 2x_a^T (\Lambda_{ab}\mu_b)) +$
 $+ x_a^T \Lambda_{aa}\left(-\frac{1}{2}x_a + \mu_a\right) + x_a^T \Lambda_{ab}\mu_b + c_5 =$
 $= -x_a^T (\Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba}\mu_a) + x_a^T (\frac{1}{2}\Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba})x_a - x_a^T (\Lambda_{ab}\mu_b) +$
 $+ x_a^T (-\frac{1}{2}\Lambda_{aa})x_a + x_a^T (\Lambda_{aa}\mu_a) + x_a^T (\Lambda_{ab}\mu_b) + c_5 =$
 $= -x_a^T (\Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba}\mu_a) + x_a^T (\frac{1}{2}\Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba})x_a +$
 $+ x_a^T (-\frac{1}{2}\Lambda_{aa})x_a + x_a^T (\Lambda_{aa}\mu_a) + c_5 =$
 $= x_a^T (\Lambda_{aa}\mu_a - \Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba}\mu_a) + x_a^T (\frac{1}{2}\Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba} - \frac{1}{2}\Lambda_{aa})x_a + c_5 =$
 $= -\frac{1}{2}x_a^T (\Lambda_{aa} - \Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba})x_a + x_a^T ((\Lambda_{aa} - \Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba})\mu_a) + c_5$
- podle Lemma 3 a definice \mathcal{N} tedy platí, že $p(x_a) \sim \mathcal{N}\left((\Lambda_{aa} - \Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba})^{-1}, \mu_a\right)$
- podle Lemma 6 je to ve skutečnosti $p(x_a) \sim \mathcal{N}(\Sigma_{aa}, \mu_a)$ □

Lemma 9 (Marginál násobku). *Pokud platí $p(x) = \mathcal{N}(x|\mu, \Lambda^{-1})$, $p(y|x) = \mathcal{N}(y|Ax + b, L^{-1})$, tak poté*

$$p(y) = \int p(y|x)p(x)dx \sim \mathcal{N}(A\mu + b, L^{-1} + AL^{-1}A^T)$$

Důkaz.

- Podíváme-li se na Lemma 8 a definujeme si například $z = \begin{pmatrix} x \\ y \end{pmatrix}$, vidíme, že jde o stejný případ.
Tj. musíme spočítat matici a rozptyl $p(y|x)p(x)$ a „výšek“, odpovídající y , je potřebný výsledek.
- $\ln p(z) = \ln p(x) + \ln p(y|x)$ - definice
- $\ln p(z) = -\frac{1}{2}(x - \mu)^T \Lambda (x - \mu) - \frac{1}{2}(y - Ax - b)^T L (y - Ax - b) + c$
 - $(x - \mu)^T \Lambda (x - \mu) = x^T \Lambda x - 2x^T \Lambda \mu + c$
 - $(y - (Ax + b))^T L (y - (Ax + b)) = y^T L y - 2(Ax + b)^T L y + (Ax + b)^T L (Ax + b) =$
 $= y^T L y - 2x^T A^T L y - 2y^T L b + x^T A^T L A x + 2x^T L A b + c$

$$- \ln p(z) = -\frac{1}{2}x^T \Lambda x + x^T \Lambda \mu - \frac{1}{2}y^T L y + x^T A^T L y + y^T L b - \frac{1}{2}x^T A^T L A x - x^T L A b + c = \\ = \left[-\frac{1}{2}x^T (\Lambda + A^T L A) x - \frac{1}{2}y^T L y + \frac{1}{2}y^T L A x + \frac{1}{2}x^T A^T L y \right] + \left[x^T (\Lambda \mu - A^T L b) + y^T L b \right]$$

– první závorka:

$$\bullet -\frac{1}{2}x^T (\Lambda + A^T L A) x - \frac{1}{2}y^T L y + \frac{1}{2}y^T L A x + \frac{1}{2}x^T A^T L y = \\ = -\frac{1}{2} \begin{pmatrix} x \\ y \end{pmatrix}^T \begin{pmatrix} \Lambda + A^T L A & -A^T L \\ -L A & L \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}$$

$$\bullet \text{ chci } \begin{pmatrix} \Lambda + A^T L A & -A^T L \\ -L A & L \end{pmatrix}^{-1}, \text{ chci použít Lemma 6}$$

$$\bullet M = \left(\Lambda + A^T L A - A^T L (L)^{-1} L A \right)^{-1} = \Lambda^{-1}$$

$$\bullet \begin{pmatrix} \Lambda + A^T L A & -A^T L \\ -L A & L \end{pmatrix}^{-1} = \\ = \begin{pmatrix} \Lambda^{-1} & -\Lambda^{-1} (-A^T L) L^{-1} \\ -L^{-1} (-L A) \Lambda^{-1} & L^{-1} + L^{-1} (-L A) \Lambda^{-1} (-A^T L) L^{-1} \end{pmatrix} = \\ = \begin{pmatrix} \Lambda^{-1} & \Lambda^{-1} A^T \\ A \Lambda^{-1} & L^{-1} + A \Lambda^{-1} A^T \end{pmatrix}$$

$$\bullet \text{ první závorka je tedy } -\frac{1}{2} \begin{pmatrix} x \\ y \end{pmatrix}^T \begin{pmatrix} \Lambda^{-1} & \Lambda^{-1} A^T \\ A \Lambda^{-1} & L^{-1} + A \Lambda^{-1} A^T \end{pmatrix}^{-1} \begin{pmatrix} x \\ y \end{pmatrix}$$

$$- \text{ druhá závorka jde napsat jako } \begin{pmatrix} x \\ y \end{pmatrix}^T \begin{pmatrix} \Lambda \mu - A^T L b \\ L b \end{pmatrix}$$

$$- \text{ tj. } \ln(p) = -\frac{1}{2} \begin{pmatrix} x \\ y \end{pmatrix}^T \begin{pmatrix} \Lambda^{-1} & \Lambda^{-1} A^T \\ A \Lambda^{-1} & L^{-1} + A \Lambda^{-1} A^T \end{pmatrix}^{-1} \begin{pmatrix} x \\ y \end{pmatrix} + \begin{pmatrix} x \\ y \end{pmatrix}^T \begin{pmatrix} \Lambda \mu - A^T L b \\ L b \end{pmatrix} + c$$

– Použijeme Lemma 3 pro převod na exponent gausiánu

– A nakonec použijeme Lemma 8.

□

Lemma 10. *Mějme $x_i \sim \mathcal{N}(\bar{x}_i, \sigma^2) \forall i \in J$ pro nějaké konečné J (\mathcal{N} je tedy univariate gaussian, x_i skalár). Pak $(x_1, x_2, \dots, x_{|J|})^T \sim \mathcal{N}(\bar{x}_1, \bar{x}_2, \dots, \bar{x}_{|J|})^T, \sigma^2 I$ (kde I je jednotková matice a \mathcal{N} je multivariate gausián)*

Důkaz.

– x jsou na sobě nezávislé.

$$- \text{ Tedy } p\left((x_1, x_2, \dots, x_{|J|})^T\right) = p(x_1)p(x_2)p(x_3)\dots$$

$$- p(x_j) \propto \exp\left(-\frac{1}{2}\left(x_j - \bar{x}_{|J|}^2 \sigma^2\right)\right) \text{ z definice}$$

$$- \text{ tedy } p\left((x_1, x_2, \dots, x_{|J|})^T\right) \propto \sum_j -\frac{1}{2}(x_j - \bar{x}_j)^2 \sigma^2$$

$$- \sum_j -\frac{1}{2}(x_j - \bar{x}_j)^2 \sigma^2 = -\frac{1}{2} \sigma^2 \sum_j (x_j - \bar{x}_j)^2 = \\ = -\frac{1}{2} \sigma^2 \left((x_1, x_2, \dots, x_{|J|}) - (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_{|J|}) \right) \left((x_1, x_2, \dots, x_{|J|}) - (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_{|J|}) \right)^T \\ = -\frac{1}{2} \sigma^2 \left((x_1, x_2, \dots, x_{|J|})^T - (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_{|J|})^T \right)^T \left((x_1, x_2, \dots, x_{|J|})^T - (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_{|J|})^T \right) \\ = -\frac{1}{2} \sigma^2 \left((x_1, x_2, \dots, x_{|J|})^T - (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_{|J|})^T \right)^T I \left((x_1, x_2, \dots, x_{|J|})^T - (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_{|J|})^T \right) \\ = -\frac{1}{2} \left((x_1, x_2, \dots, x_{|J|})^T - (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_{|J|})^T \right)^T \sigma^2 I \left((x_1, x_2, \dots, x_{|J|})^T - (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_{|J|})^T \right)$$

a z toho už nám věta plyne

□

1.3 Zpátky k problému - prediktivní distribuce

- Hlavní, co chceme zjistit, je prediktivní distribuce. Tj.

$$p(y_{new}|y_{old}, x_{old}, x_{new}, R),$$

kde R je model, co byl popsán na začátku (v R jsou „zahrnuty“ konstanty modelu). Pro jednodušší zápis nebudu podmínění R do dalších vzorečků psát.

Definice 5. Maticí Φ_{old} myslím matici $n \cdot M$, kde n je počet funkcí ϕ , M je velikost vektoru x_{old} , $\Phi_{old,i,j} = \phi_i(x_{old,j})$. Totéž s Φ_{new} .

Lemma 11 (Přepis na marginál).

$$p(y_{new}|y_{old}, x_{old}, x_{new}) = \int p(y_{new}|w, x_{new})p(w|y_{old}, x_{old})dw$$

Důkaz.

- $p(y_{new}|y_{old}, x_{old}, x_{new}) = \int p(y_{new}|w, y_{old}, x_{old}, x_{new})p(w|y_{old}, x_{old}, x_{new})dw$
- $p(y_{new}|w, y_{old}, x_{old}, x_{new}) = p(y_{new}|w, x_{new})$ - pokud už mám váhy, tak výsledek nezávisí na ničem dalším
- $p(w|y_{old}, x_{old}, x_{new}) = p(w|y_{old}, x_{old})$, protože nová data bez zdroje nám o váhách nic neřeknou \square

Lemma 12 (Přepis posterioru).

$$p(w|y_{old}, x_{old}) \propto p(w)p(y_{old}|x_{old}, w)$$

Pozn.: $p(w|y_{old}, x_{old})$ je bayesovský posterior, $p(w)$ je prior, $p(y_{old}|x_{old}, w)$ je likelihood

Důkaz.

- Z Bayesova pravidla $p(w|y_{old}, x_{old}) = \frac{p(w|x_{old})p(y_{old}|w, x_{old})}{p(y_{old}|x_{old})}$
- Z hlediska w je $p(y_{old}|x_{old})$ konstanta
- $p(w|x_{old}) = p(w)$ - bez informace o y_{old} nám x_{old} nic neřekne \square

Lemma 13 (Likelihood).

$$y_{new}|w, x_{new} \sim \mathcal{N}(\Phi_{new}w, \sigma^2 I),$$

kde I je jednotková matice. Podobně $y_{old}|w, x_{old} \sim \mathcal{N}(\Phi_{old}w, \sigma^2 I)$

Důkaz.

- pro y_{new} a y_{old} je následující postup stejný - prostě máme vstup a váhy a chceme pravděpodobnost výstupu. Tj. budu psát jen x a y (resp x_i a y_i)
- $f(x)$ si nazvu vektor $(f(x_1), f(x_2), \dots, f(x_{|x|}))^T$
- podle modelu $y_i = f(x_i) + \varepsilon_i \forall i \in \{1 \dots |y|\}$, tj. $y_i \sim \mathcal{N}(f(x_i), \sigma^2)$
- To jde napsat také jako $y \sim \mathcal{N}(f(x), \sigma^2 I)$ podle Lemma 10
- $f(x)_i = f(x_i) = \sum_{m=1}^M w_m \phi_m(x_i)$, - to je totéž, co $[\Phi w]_i$ \square

Lemma 14 (Výpočet posterioru). $w|y_{old}, x_{old} \sim \mathcal{N}(\hat{w}, \hat{\Sigma})$, kde

$$\hat{\Sigma} = (\Sigma_0^{-1} + \sigma^{-2} \Phi_{old}^T \Phi_{old})^{-1},$$

$$\hat{w} = \hat{\Sigma} (\Sigma_0^{-1} \mu_0 + \sigma^{-2} \Phi_{old}^T y_{old})$$

Důkaz.

- Podle Lemmatu 12 víme, že $p(w|y_{old}, x_{old}) \propto p(w)p(y_{old}|x_{old}, w)$
- Podle Definice 1 $w \sim \mathcal{N}(\mu_0, \Sigma_0)$, tj. $\ln p(w) = \left(-\frac{1}{2}(w - \mu_0)^T \Sigma_0^{-1}(w - \mu_0)\right) + c$, to lze přepsat podle Lemma 2 jako $-\frac{1}{2}w^T \Sigma_0^{-1}w + w^T \Sigma_0^{-1}\mu_0 + \left[-\frac{1}{2}\mu_0^T \Sigma_0^{-1}\mu_0 + c\right]$, poslední závorka je konstanta
- Podle Lemma 13 $y_{old}|x_{old}, w \sim \mathcal{N}(\Phi_{old}w, \sigma^2 I)$, tj.

$$\begin{aligned} \ln p(y_{old}|x_{old}, w) &= \left(-\frac{1}{2}(y_{old} - \Phi_{old}w)^T (\sigma^2 I)^{-1}(y_{old} - \Phi_{old}w)\right) + c = \\ &= \left(-\frac{1}{2}\sigma^{-2}(y_{old} - \Phi_{old}w)^T (y_{old} - \Phi_{old}w)\right) + c = \\ &= \left(-\frac{1}{2}\sigma^{-2}(y_{old}^T y_{old} - 2w^T \Phi_{old}^T y_{old} + w^T \Phi_{old}^T \Phi_{old} w)\right) + c \end{aligned}$$
- tedy $\ln p(w|y_{old}, x_{old}) = \left(-\frac{1}{2}w^T \Sigma_0^{-1}w + w^T \Sigma_0^{-1}\mu_0\right) + \left(-\frac{1}{2}\sigma^{-2}(y_{old}^T y_{old} - 2w^T \Phi_{old}^T y_{old} + w^T \Phi_{old}^T \Phi_{old} w)\right) + c$
- V tomto okamžiku už můžeme brát y_{old} jako konstantu, neboť nezávisí na w .
- $\ln p(w|y_{old}, x_{old}) = \left(-\frac{1}{2}w^T \Sigma_0^{-1}w + w^T \Sigma_0^{-1}\mu_0\right) + \left(-\frac{1}{2}\sigma^{-2}(-2w^T \Phi_{old}^T y_{old} + w^T \Phi_{old}^T \Phi_{old} w)\right) + c$
 $= -\frac{1}{2}w^T \Sigma_0^{-1}w + w^T \Sigma_0^{-1}\mu_0 + w^T \sigma^{-2} \Phi_{old}^T y_{old} - \frac{1}{2}\sigma^{-2}w^T \Phi_{old}^T \Phi_{old} w + c$
- Opět chceme převést do formy Lemma 3.
- $\ln p(w|y_{old}, x_{old}) = -\frac{1}{2}w^T (\Sigma_0^{-1} + \sigma^{-2} \Phi_{old}^T \Phi_{old}) w + w^T (\Sigma_0^{-1}\mu_0 + \sigma^{-2} \Phi_{old}^T y_{old}) + c =$
 $= -\frac{1}{2}w^T \hat{\Sigma}^{-1}w + w^T (\hat{\Sigma}^{-1}\hat{w})$
- Použijeme Lemma 3. □

Věta 1 (Predictive).

$$y_{new}|y_{old}, x_{old}, x_{new} \sim \mathcal{N}\left(\Phi_{new}\hat{w}, \sigma^2 I + \Phi_{new}\hat{\Sigma}\Phi_{new}^T\right)$$

Důkaz.

- Podle Lemmatu 11 víme, že $p(y_{new}|y_{old}, x_{old}, x_{new}) = \int p(y_{new}|w, x_{new})p(w|y_{old}, x_{old})dw$
- Podle Lemmatu 13 víme, že $y_{new}|w, x_{new} \sim \mathcal{N}(\Phi_{new}w, \sigma^2 I)$
- Podle Lemmatu 14 víme, že $w|y_{old}, x_{old} \sim \mathcal{N}(\hat{w}, \hat{\Sigma})$
- Použijeme Lemma 9, kde přepíšeme
 - $y \rightarrow y_{new}$
 - $x \rightarrow w$
 - $\mu \rightarrow \hat{w}$
 - $\Lambda \rightarrow \hat{\Sigma}^{-1}$
 - $L \rightarrow \sigma^{-2}I$
 - $b \rightarrow 0$
 - $A \rightarrow \Phi_{new}$
 - $\mathcal{N}(A\mu + b, L^{-1} + AL^{-1}A^T) \rightarrow \mathcal{N}\left(\Phi_{new}\hat{w}, \sigma^2 I + \Phi_{new}\hat{\Sigma}\Phi_{new}^T\right)$

□

2 Regrese s neznámou σ^2

2.1 Pomocné definice a lemmata

Definice 6 (Gamma funkce). $\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt$

Definice 7 (Gamma distribuce).

$$\text{Gam}(x|a, b) = \frac{1}{\Gamma(a)} b^a x^{a-1} \exp(-bx)$$

Lemma 15. $\text{Gam}(x|a, b) \propto x^{a-1} \exp(-bx)$

Definice 8 (Normal-Gamma).

$$\mathcal{NG}(w, \lambda|\mu_0, \Sigma_0, a, b) = \mathcal{N}(w|\mu_0, \lambda^{-1}\Sigma_0) \cdot \text{Gam}(\lambda|a, b)$$

kde w je vektor, λ je skalár, μ_0 je vektor, Σ_0 je matice, a a b jsou skaláry.

Pozn: Tato distribuce je na různých místech definována různě, já použiji tuto definici.

Lemma 16.

$$\ln(\mathcal{NG}(w, \lambda|\mu_0, \Sigma_0, a, b)) = \ln\left(\lambda^{a+\frac{|w|-2}{2}}\right) \left(-\frac{1}{2}\lambda\left((w-\mu_0)^T \Sigma_0^{-1}(w-\mu_0) + 2b\right)\right) + c$$

Důkaz.

$$\begin{aligned} -\mathcal{N}(w|\mu_0, \lambda^{-1}\Sigma_0) &= (2\pi)^{-\frac{|w|}{2}} |\lambda^{-1}\Sigma_0|^{-\frac{1}{2}} \exp\left(-\frac{1}{2}\left((w-\mu_0)^T \Sigma_0^{-1}\lambda(w-\mu_0)\right)\right) = \\ &= (2\pi)^{-\frac{|w|}{2}} (\lambda^{-|w|} |\Sigma_0|)^{-\frac{1}{2}} \exp\left(-\frac{1}{2}\left((w-\mu_0)^T \Sigma_0^{-1}\lambda(w-\mu_0)\right)\right) = \\ &= (2\pi)^{-\frac{|w|}{2}} |\Sigma_0|^{-\frac{1}{2}} \lambda^{\frac{|w|}{2}} \exp\left(-\frac{1}{2}\left((w-\mu_0)^T \Sigma_0^{-1}\lambda(w-\mu_0)\right)\right) = \\ &= C \lambda^{\frac{|w|}{2}} \exp\left(-\frac{1}{2}\lambda\left((w-\mu_0)^T \Sigma_0^{-1}(w-\mu_0)\right)\right) \end{aligned}$$

– (pozor, λ teď není konstanta)

$$-\text{Gam}(\lambda|a, b) = C \lambda^{a-1} \exp(-b\lambda)$$

$$-\mathcal{NG}(w, \lambda|\mu_0, \Sigma_0, a, b) = C \lambda^{a+\frac{|w|-2}{2}} \exp\left(-\frac{1}{2}\lambda\left((w-\mu_0)^T \Sigma_0^{-1}(w-\mu_0) + 2b\right)\right) \quad \square$$

Lemma 17. *Když Σ je poz. def. matice, tak*

$$(y - X\beta)^T(y - X\beta) + (\beta - \beta_0)\Sigma^{-1}(\beta - \beta_0) + 2b = (\beta - \beta^*)^T(\Sigma^*)^{-1}(\beta - \beta^*) + 2b^*$$

kde

$$\beta^* = (\Sigma^{-1} + X^T X)^{-1}(\Sigma^{-1}\beta_0 + X^T y)$$

$$\Sigma^* = (\Sigma^{-1} + X^T X)^{-1}$$

$$b^* = b + \frac{1}{2}(\beta_0^T \Sigma^{-1}\beta_0 + y^T y - (\beta^*)^T(\Sigma^*)^{-1}\beta^*)$$

Důkaz.

– Vezmu nejdřív levou stranu a rozpočítám jí, pak pravou a rozpočítám jí a obě vyjdou stejně.

$$\begin{aligned} &-(y - X\beta)^T(y - X\beta) + (\beta - \beta_0)\Sigma^{-1}(\beta - \beta_0) + 2b = \\ &= y^T y - 2y^T X\beta + \beta^T X^T X\beta + \beta^T \Sigma^{-1}\beta - 2\beta_0^T \Sigma^{-1}\beta + \beta_0^T \Sigma^{-1}\beta_0 + 2b \end{aligned}$$

– (Jak jsem psal někde na začátku - protože neumím dokazovat pozitivní definitnost, tak jí nedokazuju a předpokládám jí u Σ^*)

$$\begin{aligned}
& - (\beta - \beta^*)^T (\Sigma^*)^{-1} (\beta - \beta^*) = \\
& = (\beta - (\Sigma^{-1} + X^T X)^{-1} (\Sigma^{-1} \beta_0 + X^T y))^T ((\Sigma^{-1} + X^T X)^{-1})^{-1} \cdot \\
& \cdot (\beta - (\Sigma^{-1} + X^T X)^{-1} (\Sigma^{-1} \beta_0 + X^T y)) = \\
& = (\beta - (\Sigma^{-1} + X^T X)^{-1} (\Sigma^{-1} \beta_0 + X^T y))^T (\Sigma^{-1} + X^T X) \cdot \\
& \cdot (\beta - (\Sigma^{-1} + X^T X)^{-1} (\Sigma^{-1} \beta_0 + X^T y)) = \\
& = \beta^T (\Sigma^{-1} + X^T X) \beta - 2\beta^T (\Sigma^{-1} + X^T X) (\Sigma^{-1} + X^T X)^{-1} (\Sigma^{-1} \beta_0 + X^T y) + \\
& + ((\Sigma^{-1} + X^T X)^{-1} (\Sigma^{-1} \beta_0 + X^T y))^T (\Sigma^{-1} + X^T X) (\Sigma^{-1} + X^T X)^{-1} (\Sigma^{-1} \beta_0 + X^T y) = \\
& = \beta^T (\Sigma^{-1} + X^T X) \beta - 2\beta^T (\Sigma^{-1} \beta_0 + X^T y) + \\
& + ((\Sigma^{-1} + X^T X)^{-1} (\Sigma^{-1} \beta_0 + X^T y))^T (\Sigma^{-1} \beta_0 + X^T y) = \\
& = \beta^T (\Sigma^{-1} + X^T X) \beta - 2\beta^T (\Sigma^{-1} \beta_0 + X^T y) + \\
& + (\Sigma^{-1} \beta_0 + X^T y)^T ((\Sigma^{-1} + X^T X)^{-1})^T (\Sigma^{-1} \beta_0 + X^T y) = \\
& = \beta^T \Sigma^{-1} \beta + \beta^T X^T X \beta - 2\beta^T \Sigma^{-1} \beta_0 - 2\beta^T X^T y + \\
& + (\Sigma^{-1} \beta_0 + X^T y)^T ((\Sigma^{-1} + X^T X)^{-1})^T (\Sigma^{-1} \beta_0 + X^T y) = \\
& = \beta^T \Sigma^{-1} \beta + \beta^T X^T X \beta - 2\beta^T \Sigma^{-1} \beta_0 - 2\beta^T X^T y + \\
& + \beta_0^T \Sigma^{-1} ((\Sigma^{-1} + X^T X)^{-1})^T \Sigma^{-1} \beta_0 + 2y^T X ((\Sigma^{-1} + X^T X)^{-1})^T \Sigma^{-1} \beta_0 + \\
& + y^T X ((\Sigma^{-1} + X^T X)^{-1})^T X^T y = \\
& = \beta^T \Sigma^{-1} \beta + \beta^T X^T X \beta - 2\beta^T \Sigma^{-1} \beta_0 - 2\beta^T X^T y + \\
& + \beta_0^T \Sigma^{-1} (\Sigma^{-1} + X^T X)^{-1} \Sigma^{-1} \beta_0 + 2y^T X (\Sigma^{-1} + X^T X)^{-1} \Sigma^{-1} \beta_0 + \\
& + y^T X (\Sigma^{-1} + X^T X)^{-1} X^T y = \\
& = \beta^T \Sigma^{-1} \beta + \beta^T X^T X \beta - 2\beta^T \Sigma^{-1} \beta_0 - 2\beta^T X^T y + \\
& + \beta_0^T \Sigma^{-1} \Sigma^* \Sigma^{-1} \beta_0 + 2y^T X \Sigma^* \Sigma^{-1} \beta_0 + \\
& + y^T X \Sigma^* X^T y \\
& - 2b^* = 2b + \beta_0^T \Sigma^{-1} \beta_0 + y^T y - (\beta^*)^T (\Sigma^*)^{-1} \beta^* = \\
& = 2b + \beta_0^T \Sigma^{-1} \beta_0 + y^T y - \\
& ((\Sigma^{-1} + X^T X)^{-1} (\Sigma^{-1} \beta_0 + X^T y))^T ((\Sigma^{-1} + X^T X)^{-1})^{-1} (\Sigma^{-1} + X^T X)^{-1} \cdot \\
& (\Sigma^{-1} \beta_0 + X^T y) = \\
& = 2b + \beta_0^T \Sigma^{-1} \beta_0 + y^T y - \\
& ((\Sigma^{-1} + X^T X)^{-1} (\Sigma^{-1} \beta_0 + X^T y))^T (\Sigma^{-1} \beta_0 + X^T y) = \\
& = 2b + \beta_0^T \Sigma^{-1} \beta_0 + y^T y - \\
& (\Sigma^{-1} \beta_0 + X^T y)^T (\Sigma^{-1} + X^T X)^{-1} (\Sigma^{-1} \beta_0 + X^T y) = \\
& = 2b + \beta_0^T \Sigma^{-1} \beta_0 + y^T y - (\\
& \beta_0^T \Sigma^{-1} (\Sigma^{-1} + X^T X)^{-1} \Sigma^{-1} \beta_0 + \\
& + 2\Sigma^{-1} \beta_0 (\Sigma^{-1} + X^T X)^{-1} X^T y + y^T X (\Sigma^{-1} + X^T X)^{-1} X^T y) = \\
& = 2b + \beta_0^T \Sigma^{-1} \beta_0 + y^T y - \beta_0^T \Sigma^{-1} \Sigma^* \Sigma^{-1} \beta_0 - 2\Sigma^{-1} \beta_0 \Sigma^* X^T y - y^T X \Sigma^* X^T y \\
& - (\beta - \beta^*)^T (\Sigma^*)^{-1} (\beta - \beta^*) + 2b^* = \\
& = \beta^T \Sigma^{-1} \beta + \beta^T X^T X \beta - 2\beta^T \Sigma^{-1} \beta_0 - 2\beta^T X^T y + \\
& + \beta_0^T \Sigma^{-1} \Sigma^* \Sigma^{-1} \beta_0 + 2y^T X \Sigma^* \Sigma^{-1} \beta_0 + y^T X \Sigma^* X^T y + \\
& 2b + \beta_0^T \Sigma^{-1} \beta_0 + y^T y - \beta_0^T \Sigma^{-1} \Sigma^* \Sigma^{-1} \beta_0 - 2\Sigma^{-1} \beta_0 \Sigma^* X^T y - y^T X \Sigma^* X^T y = \\
& = \beta^T \Sigma^{-1} \beta + \beta^T X^T X \beta - 2\beta^T \Sigma^{-1} \beta_0 - 2\beta^T X^T y + \\
& 2b + \beta_0^T \Sigma^{-1} \beta_0 + y^T y = \\
& = y^T y - 2y^T X \beta + \beta^T X^T X \beta + \beta^T \Sigma^{-1} \beta - 2\beta_0^T \Sigma^{-1} \beta + \beta_0^T \Sigma^{-1} \beta_0 + 2b
\end{aligned}$$

□

Definice 9 (Multivariate student).

$$\text{St}(x|\mu, \Lambda, v) = \frac{\Gamma(|x|/2 + v/2)}{\Gamma(v/2)} \frac{|\Lambda|^{\frac{1}{2}}}{(\pi v)^{|x|/2}} \left[1 + \frac{((x - \mu)^T \Lambda (x - \mu))^2}{v} \right]^{-|x|/2 - v/2}$$

Lemma 18.

$$\int \mathcal{NG}(\lambda, w|\mu, \Sigma, a, b) d(\lambda, w) = \int \text{St}(w|\mu_0, l(\Sigma^{-1}), v)$$

kde $l = a/b, v = 2a$

Důkaz.

$$\begin{aligned}
& - \int \mathcal{NG}(\lambda, w | \mu_0, \Sigma_0, a, b) d(\lambda, w) = \\
& = \int \int (2\pi)^{-\frac{|w|}{2}} |\Sigma_0|^{-\frac{1}{2}} \lambda^{\frac{|w|}{2}} \exp\left(-\frac{1}{2}\lambda \left((w - \mu_0)^T \Sigma_0^{-1} (w - \mu_0) + 2b\right)\right) \frac{1}{\Gamma(a)} b^a \lambda^{a-1} d\lambda dw = \\
& = \int (2\pi)^{-\frac{|w|}{2}} |\Sigma_0|^{-\frac{1}{2}} \frac{1}{\Gamma(a)} b^a \int \lambda^{\frac{|w|}{2}} \exp\left(-\frac{1}{2}\lambda \left((w - \mu_0)^T \Sigma_0^{-1} (w - \mu_0) + 2b\right)\right) \lambda^{a-1} d\lambda dw \\
& - \text{označím } \Delta = \frac{1}{2} \left((w - \mu_0)^T \Sigma_0^{-1} (w - \mu_0) + 2b\right), z = \lambda \Delta \\
& \quad \bullet \int \lambda^{\frac{|w|}{2}+a-1} \exp\left(-\frac{1}{2}\lambda \left((w - \mu_0)^T \Sigma_0^{-1} (w - \mu_0) + 2b\right)\right) d\lambda = \\
& \quad = \int \lambda^{\frac{|w|}{2}+a-1} \exp(-z) d\lambda = \int z^{\frac{|w|}{2}+a-1} \Delta^{-(\frac{|w|}{2}+a-1)} \exp(-z) d\lambda = \\
& \quad = \Delta^{-(\frac{|w|}{2}+a-1)} \int z^{\frac{|w|}{2}+a-1} \exp(-z) d\lambda = \Delta^{-(\frac{|w|}{2}+a-1)} \int z^{\frac{|w|}{2}+a-1} \exp(-z) \Delta^{-1} dz = \\
& \quad = \Delta^{-(\frac{|w|}{2}+a)} \int z^{\frac{|w|}{2}+a-1} \exp(-z) dz = \Delta^{-(\frac{|w|}{2}+a)} \Gamma\left(\frac{|w|}{2} + a\right) \\
& - = \int (2\pi)^{-\frac{|w|}{2}} |\Sigma_0|^{-\frac{1}{2}} \frac{1}{\Gamma(a)} b^a \Delta^{-(\frac{|w|}{2}+a)} \Gamma\left(\frac{|w|}{2} + a\right) dw \\
& = \int (2\pi)^{-\frac{|w|}{2}} |\Sigma_0|^{-\frac{1}{2}} \frac{1}{\Gamma(v/2)} \left(\frac{v}{2l}\right)^{v/2} \left(\frac{v}{2l} + \frac{1}{2} \left((w - \mu_0)^T \Sigma_0^{-1} (w - \mu_0)\right)\right)^{-(\frac{|w|}{2}+v/2)} \\
& \cdot \Gamma\left(\frac{|w|+v}{2}\right) dw = \\
& = \int (2\pi)^{-\frac{|w|}{2}} |\Sigma_0|^{-\frac{1}{2}} \frac{1}{\Gamma(v/2)} \left(\frac{v}{2l}\right)^{v/2} \left(\frac{v}{2l}\right)^{-(\frac{|w|}{2}+v/2)} \\
& \cdot \left(1 + \frac{l}{v} \left((w - \mu_0)^T \Sigma_0^{-1} (w - \mu_0)\right)\right)^{-(\frac{|w|}{2}+v/2)} \Gamma\left(\frac{|w|+v}{2}\right) dw = \\
& = \int (2\pi)^{-\frac{|w|}{2}} |\Sigma_0|^{-\frac{1}{2}} \frac{1}{\Gamma(v/2)} \left(\frac{v}{2l}\right)^{-\frac{|w|}{2}} \\
& \cdot \left(1 + \frac{l}{v} \left((w - \mu_0)^T \Sigma_0^{-1} (w - \mu_0)\right)\right)^{-(\frac{|w|}{2}+v/2)} \Gamma\left(\frac{|w|+v}{2}\right) dw = \\
& = \int \frac{\Gamma(\frac{|w|+v}{2})}{\Gamma(v/2)} \frac{|l^{-1}\Sigma_0|^{-\frac{1}{2}}}{(\pi)^{1/2}} \left(\frac{v}{2l}\right)^{-\frac{|w|}{2}} \\
& \cdot \left(1 + \frac{l}{v} \left((w - \mu_0)^T (l^{-1}\Sigma_0)^{-1} (w - \mu_0)\right)\right)^{-(\frac{|w|}{2}+v/2)} dw = \int \text{St}(w | \mu_0, l(\Sigma_0^{-1}), v) dw
\end{aligned}$$

□

2.2 Definice problému

Definice 10 (Model regrese se známou σ^2).

- Jedná se přesně o stejnou defici, jako Definice 1, jen platí, že **neznáme** σ^2 (ale pořád předpokládáme, že nějaká existuje) a **změníme** priorní distribuci na w
- Dále si dáme na σ^2 a w prior tak, že $(w, \lambda) \sim \mathcal{NG}(\mu_0, \Sigma_0, a, b)$ a $\lambda = \sigma^{-2}$, kde dáme konstanty μ_0, Σ_0, a, b
- Tj. konstanty jsou $\mu_0, \Sigma_0, a, b, \{\phi_i\}$, chápu to opět vše jako součást modelu R .

2.3 Prediktivní distribuce

- Opět. Hlavní, co chceme zjistit, je prediktivní distribuce. Tj.

$$p(y_{new} | y_{old}, x_{old}, x_{new}, R),$$

přičemž R budu opět vynechávat

Lemma 19 (Přepis na marginál).

$$p(y_{new} | y_{old}, x_{old}, x_{new}) = \int p(y_{new} | w, \lambda, x_{new}) p(w, \lambda | y_{old}, x_{old}) d(w, \lambda)$$

Pozn.: Nejsem si jist, zda je takovýto zápis integrálu vůbec legální, doufám, že ano. Pokud ne, tak si v duchu představte vektor (w, λ) jako novou proměnnou.

Důkaz.

– Totéž jako u Lemmatu 11. □

Lemma 20 (Přepis posterioru).

$$p(w, \lambda | y_{old}, x_{old}) \propto p(w, \lambda) p(y_{old} | x_{old}, w, \lambda)$$

Důkaz.

– Totéž, co Lemma 12 □

Lemma 21 (Likelihood).

$$y_{new} | w, \lambda, x_{new} \sim \mathcal{N}(\Phi_{new} w, \lambda^{-1} I),$$

kde I je jednotková matice. Podobně $y_{old} | w, \lambda, x_{old} \sim \mathcal{N}(\Phi_{old} w, \lambda^{-1} I)$

Důkaz.

– Totéž co Lemma 13 □

Lemma 22.

$$\ln(p(y_{old} | w, \lambda, x_{old})) = \lambda^{\frac{|y_{old}|}{2}} \left(-\frac{1}{2} \lambda (y_{old} - \Phi_{old} w)^T (y_{old} - \Phi_{old} w) \right) + c,$$

kde λ nebereme jako konstantu

Důkaz.

– Víceméně totéž, co v první odrážce důkazu Lemma 16 □

Lemma 23 (Výpočet posterioru). $w, \lambda | y_{old}, x_{old} \sim \mathcal{NG}(\hat{w}, \hat{\Sigma}, \hat{a}, \hat{b})$, kde

$$\begin{aligned} \hat{w} &= (\Sigma_0^{-1} + \Phi_{old}^T \Phi_{old})^{-1} (\Sigma_0^{-1} \mu_0 + \Phi_{old}^T y_{old}) \\ \hat{\Sigma} &= (\Sigma_0^{-1} + \Phi_{old}^T \Phi_{old})^{-1} \\ \hat{b} &= b + \frac{1}{2} (\mu_0^T \Sigma_0^{-1} \mu_0 + y_{old}^T y_{old} - \hat{w}^T \hat{\Sigma}^{-1} \hat{w}) \\ \hat{a} &= a + \frac{1}{2} |y_{old}| \end{aligned}$$

Důkaz.

- Podle Lemmatu 20 víme, že $p(w, \lambda | y_{old}, x_{old}) \propto p(w, \lambda) p(y_{old} | x_{old}, w, \lambda)$
- Podle Definice 10 $w, \lambda \sim \mathcal{NG}(\mu_0, \Sigma_0, a, b)$
- $\ln p(w, \lambda) = \ln \left(\lambda^{a + \frac{|w|^2 - 2}{2}} \right) \left(-\frac{1}{2} \lambda \left((w - \mu_0)^T \Sigma_0^{-1} (w - \mu_0) + 2b \right) \right) + c$ podle Lemma 16
- Podle Lemma 22 $\ln(p(y_{old} | w, \lambda, x_{old})) = \lambda^{\frac{|y_{old}|}{2}} \left(-\frac{1}{2} \lambda (y_{old} - \Phi_{old} w)^T (y_{old} - \Phi_{old} w) \right) + c$
- $\ln p(w, \lambda | y_{old}, x_{old}) = \ln \left(\lambda^{a + \frac{|w| + |y_{old}| - 2}{2}} \right) \cdot \left(-\frac{1}{2} \lambda \left((w - \mu_0)^T \Sigma_0^{-1} (w - \mu_0) + (y_{old} - \Phi_{old} w)^T (y_{old} - \Phi_{old} w) + 2b \right) \right) + c$
- Použiji Lemma 17 a jednoduchou úpravu exponentu λ
- $\ln p(w, \lambda | y_{old}, x_{old}) = \ln \left(\lambda^{\hat{a} + \frac{|w| - 2}{2}} \right) \left(-\frac{1}{2} \lambda \left((w - \hat{w})^T \hat{\Sigma}^{-1} (w - \hat{w}) + 2\hat{b} \right) \right) + c$

– Podle Lemmatu 16 jde o dané \mathcal{NG} . □

Věta 2 (Predictive nedopočítaný).

$$p(y_{new}|y_{old}, x_{old}, x_{new}) \propto \int \text{St} \left(w|\check{w}, \check{l} \left(\check{\Sigma}^{-1} \right), \check{v} \right) dw,$$

kde

$$\begin{aligned} \check{w} &= (\hat{\Sigma}^{-1} + \Phi_{new}^T \Phi_{new})^{-1} (\hat{\Sigma}^{-1} \hat{w} + \Phi_{new}^T y_{new}) \\ \check{\Sigma} &= (\hat{\Sigma}^{-1} + \Phi_{new}^T \Phi_{new})^{-1} \\ \check{b} &= \hat{b} + \frac{1}{2} (\hat{w}^T \hat{\Sigma}_0^{-1} \hat{w} + y_{new}^T y_{new} - \check{w}^T \check{\Sigma}^{-1} \check{w}) \\ \check{a} &= \hat{a} + \frac{1}{2} |y_{new}| \\ \check{l} &= \check{a} / \check{b} \\ \check{v} &= 2\check{a} \end{aligned}$$

Nedokázal jsem, bohužel, dopočítat tenhle integrál do konce.

Bishop uvádí, že konečný integrál je studentovo rozdělení, ale neuvádí výpočet a nechává ho jako cvičení. Je možné, že mám někde ve výpočtu chybu - at' numerickou nebo logickou; nebo jsem Bishopa špatně pochopil; nebo jenom neumím integrovat studentovo rozdělení.

Proto to takhle nechám, protože nevím, co s tím dál. Ještě důkaz.

Důkaz.

– Podle Lemmatu 19 víme, že

$$p(y_{new}|y_{old}, x_{old}, x_{new}) = \int p(y_{new}|w, \lambda, x_{new}) p(w, \lambda|y_{old}, x_{old}) d(w, \lambda)$$

– Podle Lemmatu 21 víme, že $y_{new}|w, \lambda, x_{new} \sim \mathcal{N}(\Phi_{new} w, \lambda^{-1} I)$

– Podle Lemmatu 23 víme, že $w|y_{old}, x_{old} \sim \mathcal{NG}(\hat{w}, \hat{\Sigma}, \hat{a}, \hat{b})$

$$\begin{aligned} & \text{– Tedy počítám } \int \mathcal{N}(y_{new}|\Phi_{new} w, \lambda^{-1} I) \mathcal{NG}(w, \lambda|\hat{w}, \hat{\Sigma}, \hat{a}, \hat{b}) d(w, \lambda) = \\ & = \int \mathcal{N}(y_{new}|\Phi_{new} w, \lambda^{-1} I) \mathcal{N}(w|\hat{w}, \lambda^{-1} \hat{\Sigma}) \text{Gam}(\lambda|\hat{a}, \hat{b}) d(w, \lambda) = \\ & = \int 2\pi^{-|y_{new}|/2} |\lambda^{-1} I|^{-1} \exp\left(-\frac{1}{2} \lambda (y_{new} - \Phi_{new} w)^T (y_{new} - \Phi_{new} w)\right) \cdot \\ & \cdot 2\pi^{-|w|/2} \left|\lambda^{-1} \hat{\Sigma}\right|^{-1} \exp\left(-\frac{1}{2} \lambda (w - \hat{w})^T \hat{\Sigma} (w - \hat{w})\right) \lambda^{\hat{a}-1} \exp(-\hat{b}\lambda) d(w, \lambda) = \\ & = 2\pi^{-|y_{new}|/2} 2\pi^{-|w|/2} \frac{1}{\Gamma(\hat{a})} \hat{b}^{\hat{a}} \cdot \\ & \int \lambda^{|y_{new}|/2 + |w|/2 + \hat{a} - 1} \cdot \\ & \exp\left(-\frac{1}{2} \lambda \left((y_{new} - \Phi_{new} w)^T (y_{new} - \Phi_{new} w) + (w - \hat{w})^T \hat{\Sigma} (w - \hat{w}) + 2\hat{b}\right)\right) d(w, \lambda) \propto \\ & \propto \int \lambda^{|y_{new}|/2 + |w|/2 + \hat{a} - 1} \cdot \\ & \exp\left(-\frac{1}{2} \lambda \left((y_{new} - \Phi_{new} w)^T (y_{new} - \Phi_{new} w) + (w - \hat{w})^T \hat{\Sigma} (w - \hat{w}) + 2\hat{b}\right)\right) d(w, \lambda) \\ & \text{– použijeme Lemma 17} \\ & \text{– ...} = \int \lambda^{\hat{a} + \frac{|w|}{2}} \exp\left(-\frac{1}{2} \lambda \left((w - \check{w})^T \check{\Sigma}^{-1} (w - \check{w}) + 2\check{b}\right)\right) d(w, \lambda) = \\ & = \int \mathcal{NG}(\lambda, w|\check{w}, \check{\Sigma}, \check{a}, \check{b}) d(w, \lambda) \\ & \text{– Použijeme Lemma 18.} \end{aligned}$$

□

3 Zdroje

– Bishop, Christopher M., and Nasser M. Nasrabadi. Pattern recognition and machine learning. Vol. 1. New York: springer, 2006.

- The Bayesian Linear Model with unknown Variance, Simon Kunz http://www.biostat.uzh.ch/teaching/master/previous/seminarbayes/SimonKunz_article.pdf.
- články na anglické wikipedii